Universidad Nacional Autónoma de México

Facultad de Ciencias

Almacenes y minería de Datos

Profesora:

- ★ Jessica Santizo Galicia

Ayudantes:

- ★ Diego Antonio Villalba Gónzalez
- ★ Ares Gael Castro Romero

Grupo 7171

Integrantes :

- ★ Cano Tenorio Alan Kevin (321259967)
- ★ Gomez Calva Carlos Manuel (321281678)
- ★ Lechuga Hervert Maximiliano (321311186)
- ★ Vázquez Rincón Oscar (321228954)

I. Empresa y metodología de Minería de Datos

- ☐ Cano Tenorio Alan Kevin

Empresa elegida: Amazon

Amazon emplea el modelo de negocio Flywheel, el cual se basa en la minería de datos para impulsar su crecimiento. Este enfoque consiste en la recolección masiva de información de los clientes para mejorar su experiencia dentro de la plataforma y, como resultado, tener más tráfico, generando así un ciclo continuo de expansión. utiliza el framework Machine Learning Lens, el cuál establece las mejores prácticas a lo largo de todo el ciclo de vida de los datos, desde su recolección inicial hasta el monitoreo continuo de los modelos en producción

Fuentes:

- ☐ Feedvisor. (2023). *Amazon Flywheel Explained: How the Virtuous Cycle Drives Growth. Feedvisor.*. Recuperado el 26 de marzo de 2026, de https://feedvisor.com/resources/amazon-trends/amazon-flywheel-explained/
- ☐ AWS. (2025, 19 de noviembre). *Machine Learning Lens - AWS Well-Architected Framework*. Amazon Web Services. Recuperado el 26 de marzo de 2026, de https://docs.aws.amazon.com/wellarchitected/latest/machine-learning-lens/machine-learning-lens.html

- Gómez Calva Carlos Manuel

Empresa elegida: Riot Games

Metodología: Player-Driven Data Mining (Adaptación de KDD)

Riot Games utiliza una metodología de Minería de Datos altamente especializada en el análisis del comportamiento del usuario y el equilibrio del juego (game balance). Su enfoque se basa en el proceso de KDD (Knowledge Discovery in Databases), pero adaptado a flujos de datos en tiempo real. La empresa prioriza la fase de Preprocesamiento y Transformación, donde limpian millones de registros diarios de partidas para alimentar modelos de aprendizaje automático que detectan comportamientos tóxicos o predicen el "churn" (abandono) de jugadores. Su metodología destaca por el uso de pruebas A/B constantes para validar si los cambios en el código del juego mejoran la experiencia del usuario.

Sustento:

- Riot Games Technology. (2023). *Data Science and Machine Learning at Riot*. Engineering Blog. Recuperado de https://technology.riotgames.com/
- Drachen, A., & Canossa, A. (2022). *Game Data Science: A Practical Guide*. Oxford University Press.

➔ Lechuga Hervert Maximiliano

Empresa Elegida: X-BOX

Xbox, como parte de Microsoft, utiliza principalmente el Team Data Science Process (TDSP) para el desarrollo de proyectos de minería de datos y análisis avanzado. TDSP es una metodología ágil e iterativa que combina los principios de CRISP-DM (Cross-Industry Standard Process for Data Mining) con prácticas modernas de ingeniería de software y DevOps, cuyo objetivo es cómo mejorar la retención de los jugadores,

personalizar recomendaciones, para ello hace la recolección de los juegos, el perfil de jugador y su comportamiento para después hacer uso de Machine Learning para encontrar patrones, validarlo y despues hacer la implementación para su análisis

Fuentes:

➔ Datascience-pm.com. (2018, 11 de septiembre). *What is TDSP?* Recuperado el 26 de marzo de 2026, de https://www.datascience-pm.com/tdsp/

★ Oscar Vazquez Rincon

Empresa Elegida: Electronics Arts

Metodología utilizada: Usa trabajos ágiles(Agile Data Science) con CRISP

Electronics Arts(EA) usa la adaptación del estándar CRISP-DM donde lo combina en juegos modernos como servicio donde se le generan terabytes de datos, para el procesamiento de datos se usa un enfoque ágil que permite micro-ciclos rápidos. Donde ejecutan pruebas para el ajuste de algoritmos de emparejamiento, detectar fraudes y predecir el abandono de jugadores . Todo esto permite que los modelos predictivos puedan parchear los balanceos y mejoras en los juegos que ofrecen como servicio.

Fuentes:]

★ El-Nasr, M. S., Drachen, A., & Canossa, A. (2013). *Game Analytics: Maximizing the Value of Player Data*. Springer.

(Capítulos sobre procesos de minería de datos en la industria de los videojuegos).

★ Replay Game Lab / JKU. (2022). *Game Data Mining and the Value of Visual Analytics*. Recuperado de la investigación sobre metodologías de análisis de comportamiento de jugadores.

II. Descripción del Dataset

El dataset trabajado Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO) mediante un análisis de sus características nos encontramos con que:

- Número de filas: 116,945 registros.
- Número de columnas: 11 variables descriptivas.
- Periodo de fechas cubierto: Desde el 01/05/1968 hasta el 20/08/2023.
- Unidad de análisis: Cada fila representa un reporte individual de una persona desaparecida o no localizada. Se identifica por un número de registro y se encuentra asociado a una autoridad.

III. Hallazgos

- La distribución de la edad de las personas desaparecidas presenta un sesgo hacia la derecha, lo que indica que la media es la medida de tendencia central de mayor magnitud, esto sugiere una mayor probabilidad de desaparición para personas menores de 31 años.
- El valor de la moda fue de 16 años lo que muestra una alta vulnerabilidad para la población adolescente.

- La desviación estándar fue de 15.18 años, esto refleja una dispersión considerable en los datos y de la misma manera muestra varios valores atípicos superiores a los 70 años, lo que indica que los adultos mayores no están exentos de ser víctimas de desaparición.

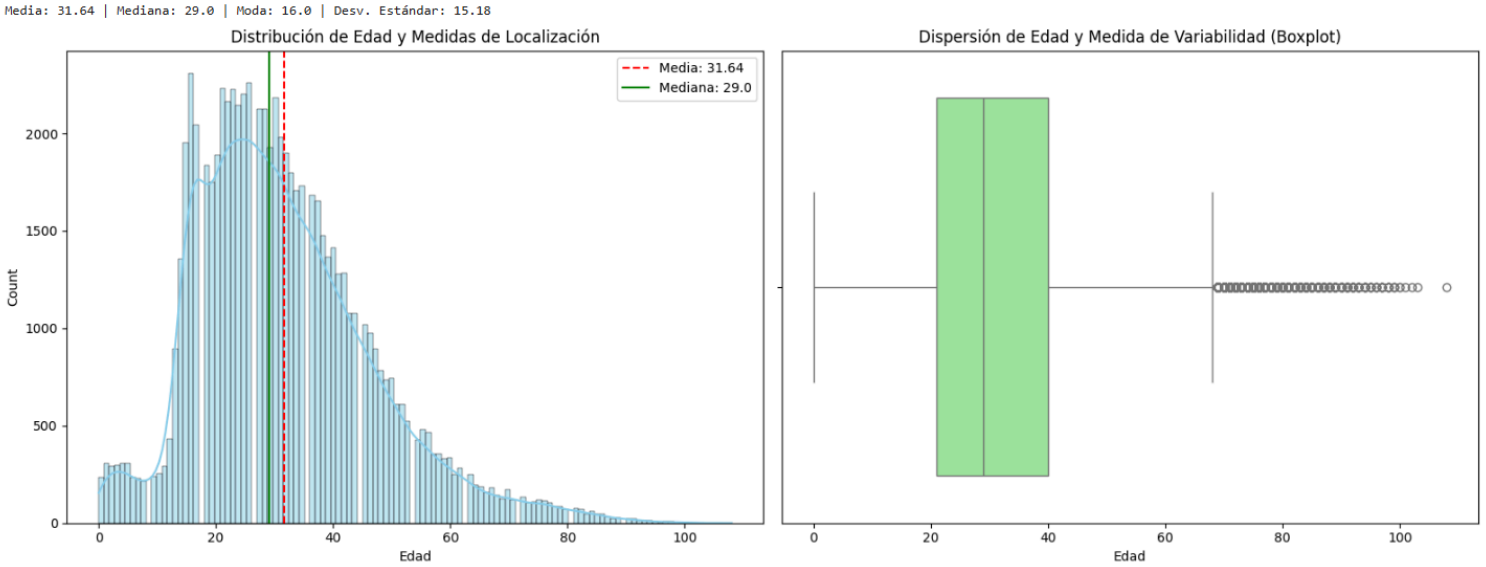

- Se observa una baja heterogeneidad en cuanto al sexo de las personas desaparecidas, ya que el 75.5 % corresponde al sexo masculino.
- 10 entidades federativas concentran el 71% de todas las desapariciones consecuencia de una heterogeneidad baja considerando que existen 32 entidades federativas

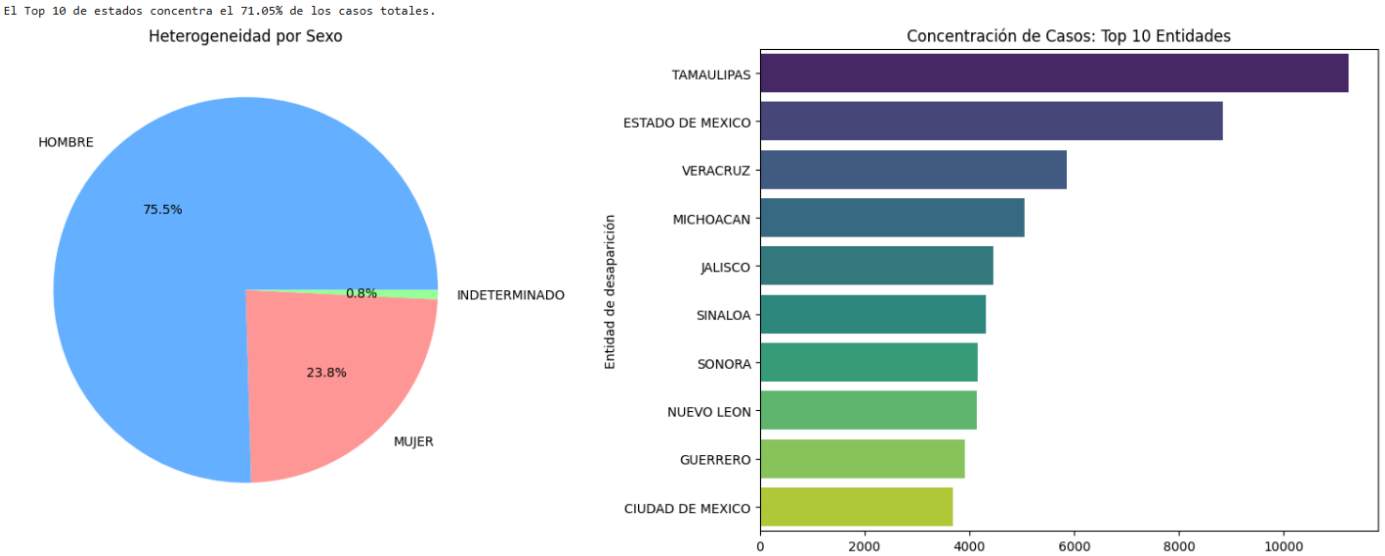

- Tamaulipas y el Estado de México presentan la mayor cantidad de desapariciones, lo cual sugiere que hay varios factores de riesgo que contribuyen a los números tan altos que presentan
- A partir de la matriz de correlacion encontramos que la correlacion mas fuerte es una relacion leve entre la edad de la persona y su sexo al momento de desaparecer
- La edad y la entidad no presentan correlación alguna siendo esta la correlación más débil presente en el dataset

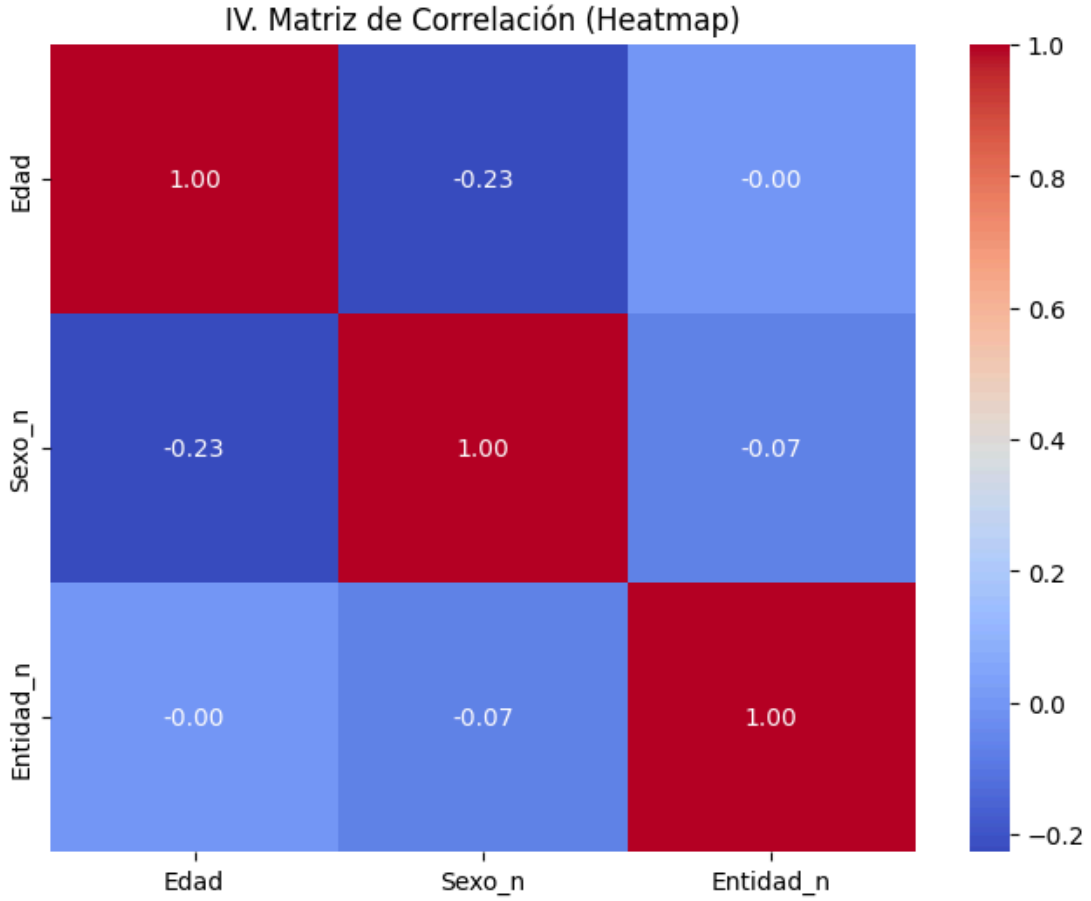

IV. Limitaciones

- **Calidad de los datos:** Se observa una presencia masiva de etiquetas "ELIMINADO" en columnas críticas (como la edad o el sexo).

- **Sesgos**
    - Subregistro (casos no denunciados)
    - Datos anonimizados para realizar un análisis de nombres o fechas exactas en ciertos registros.
- **Variables faltantes:** Presencia de “ELIMINADO” en sexo, fecha y edad
- **Decisiones de limpieza y transformación**
    - Conversión de las cadenas de texto "ELIMINADO" a valores nulos (`NaN`) en las columnas de `Edad` y `Fecha de desaparición`.
    - Cambio de tipos de datos de `string` a `int` para la Edad y a `datetime` para las fechas, permitiendo cálculos matemáticos y temporales.

V. Conclusión

El realizar la correcta limpieza de los datos junto con un buen uso de la metodología escogida de acuerdo a las características que presenta el dataset permite llevar a cabo de manera satisfactoria el análisis, comprensión e interpretación de los datos contenidos para poder mostrar el cómo se están comportando dichos datos, cuales son los datos ocultos que aportan una gran noción acerca del por que es que se tienen esas cifras, además del uso de medidas de tendencia central para las variables cuantitativas, los grafos que son de mucha ayuda para ver los datos de una manera práctica, las medidas de heterogeneidad (dispersión) para las cualitativas y en base a eso entender que es lo que está realmente pasando ahí para dar una solución o una implementación diferente para lograr una mejora